

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, classification_report
```

```
df = pd.read_csv('/content/adult.csv')
```

```
df.head()
```

	age	workclass	fnlwgt	education	education.num	marital.status	...
0	90	?	77053	HS-grad	9	Widowed	
1	82	Private	132870	HS-grad	9	Widowed	
2	66	?	186061	Some-college	10	Widowed	
3	54	Private	140359	7th-8th	4	Divorced	
4	41	Private	264663	Some-college	10	Separated	

Các bước tiếp theo:

[Tạo mã bằng df](#)[New interactive sheet](#)

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 32561 entries, 0 to 32560
Data columns (total 15 columns):
#   Column                Non-Null Count  Dtype
---  -
0   age                   32561 non-null  int64
1   workclass              32561 non-null  object
2   fnlwgt                 32561 non-null  int64
3   education              32561 non-null  object
4   education.num          32561 non-null  int64
5   marital.status         32561 non-null  object
6   occupation              32561 non-null  object
7   relationship           32561 non-null  object
8   race                   32561 non-null  object
9   sex                    32561 non-null  object
10  capital.gain            32561 non-null  int64
11  capital.loss            32561 non-null  int64
12  hours.per.week          32561 non-null  int64
13  native.country          32561 non-null  object
14  income                  32561 non-null  object
dtypes: int64(6), object(9)
memory usage: 3.7+ MB
```

```
df.isnull().sum()
```

	0
age	0
workclass	0
fnlwgt	0
education	0
education.num	0
marital.status	0
occupation	0
relationship	0
race	0
sex	0
capital.gain	0
capital.loss	0
hours.per.week	0
native.country	0
income	0


dtype: int64

```
# 1.2 Xử lý giá trị ngoại lệ (Outliers) cho cột 'hours.per.week' [ci
# Sử dụng phương pháp IQR để đảm bảo dữ liệu không bị nhiễu [cite: 4
Q1 = df['hours.per.week'].quantile(0.25)
Q3 = df['hours.per.week'].quantile(0.75)
IQR = Q3 - Q1
df_clean = df[~((df['hours.per.week'] < (Q1 - 1.5 * IQR)) | (df['hou
```

```
print(f"Dữ liệu sau khi làm sạch. Số dòng gốc: {len(df)}, Số dòng sạ
```


```
Dữ liệu sau khi làm sạch. Số dòng gốc: 32561, Số dòng sạch: 23553 [c
```

```
# 2.1 Kiểm định giả thuyết: Trình độ học vấn có ảnh hưởng đến thu n
plt.figure(figsize=(12, 6))
sns.countplot(data=df_clean, x='education', hue='income', order=df_
plt.xticks(rotation=45)
plt.title("Phân phối thu nhập theo trình độ học vấn [cite: 69]")
plt.show()
```



```
# 2.2 Phân tích tương quan [cite: 64]
# Chuyển đổi mục tiêu 'income' sang dạng số (0 và 1) để tính toán
# Strip khoảng trắng trong cột income phòng trường hợp CSV có paddi
df_clean['income'] = df_clean['income'].str.strip()
df_clean['income_binary'] = df_clean['income'].map({'<=50K': 0, '>5
```

```
plt.figure(figsize=(10, 6))
numeric_df = df_clean.select_dtypes(include=[np.number])
sns.heatmap(numeric_df.corr(), annot=True, cmap='RdBu_r', fmt='.2f')
plt.title("Ma trận tương quan: Xác định các yếu tố chính ảnh hưởng")
plt.show()
```



```
# 3.1 Biểu đồ cột: Nghề nghiệp vs Thu nhập [cite: 69]
occupation_income = df_clean.groupby('occupation')['income_binary']
plt.figure(figsize=(12, 6))
occupation_income.plot(kind='barh', color='steelblue')
plt.title("Tỷ lệ thu nhập cao (>50K) theo nhóm ngành nghề [cite: 45
```

```
plt.xlabel("Tỷ lệ (0 đến 1)")
plt.tight_layout()
plt.show()
# DIỄN GIẢI: Nhóm quản lý (Exec-managerial) có khả năng đạt mức thu
```

3.2 Biểu đồ hộp (Boxplot): Độ tuổi vs Thu nhập [cite: 65, 70]

```
plt.figure(figsize=(10, 5))
sns.boxplot(data=df_clean, x='income', y='age')
plt.title("Phân phối độ tuổi theo mức thu nhập [cite: 65]")
plt.show()
# DIỄN GIẢI: Những người thu nhập cao thường có độ tuổi trung bình
```

